Classificação 2.0

Gabriel Fernandes Silva

Pré-Processamento

1420 IES

1335 ativas 85 extintas

#	Column	Non-Null Count	Dtype
0	Codigo da IES	1420 non-null	int64
1	Fim Lucrativo	1420 non-null	int64
2	Situacao	1420 non-null	int64
3	DIAS	1420 non-null	int64
4	Cursos Sem Ato 5 anos	1420 non-null	float64
5	Ultimo CI	1420 non-null	float64
6	Ultimo IGC	1420 non-null	float64
7	EAD 17	1420 non-null	int64
8	Varīacao Matricula 16/17	1420 non-null	float64
9	Matriculas 17	1420 non-null	int64
10	% FIES	1420 non-null	float64
11	CURSOS	1420 non-null	int64
12	Saldo 2017	1420 non-null	float64
13	Variacao do Saldo 16/17	1420 non-null	float64

Balanceamento

Antes do Oversampling:

Extintas: 66 Ativas: 1070

Depois do Oversampling:

Extintas: 1070 Ativas: 1070

```
smote = SMOTE()
X_train_balanceado, y_train_balanceado = smote.fit_resample( X_train, y_train )
```

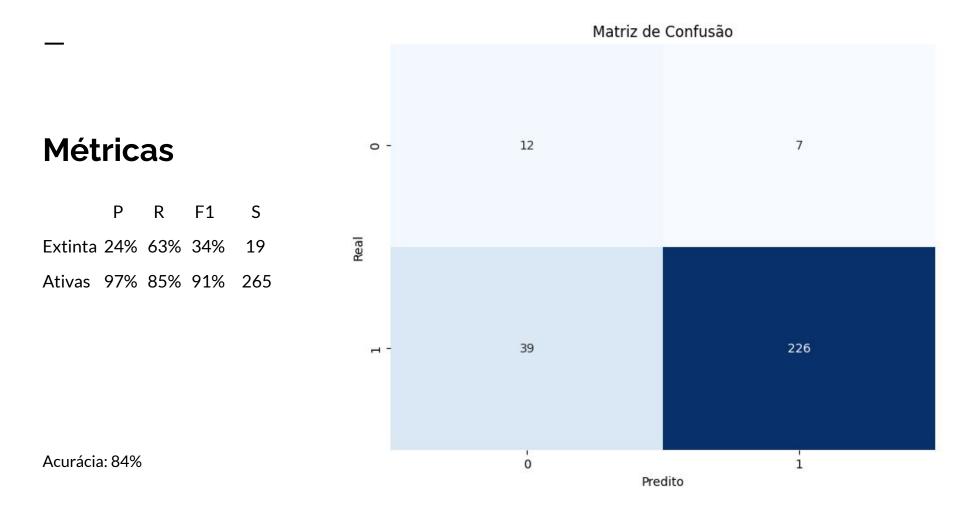
Modelo 1

KNN

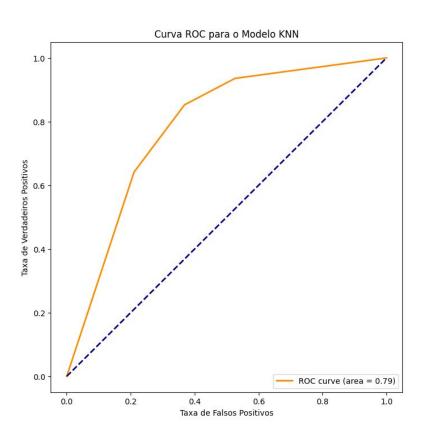
Separeção dos Dados

- 80% treino
- 20% teste

- n_neighbors = 3



Curva ROC



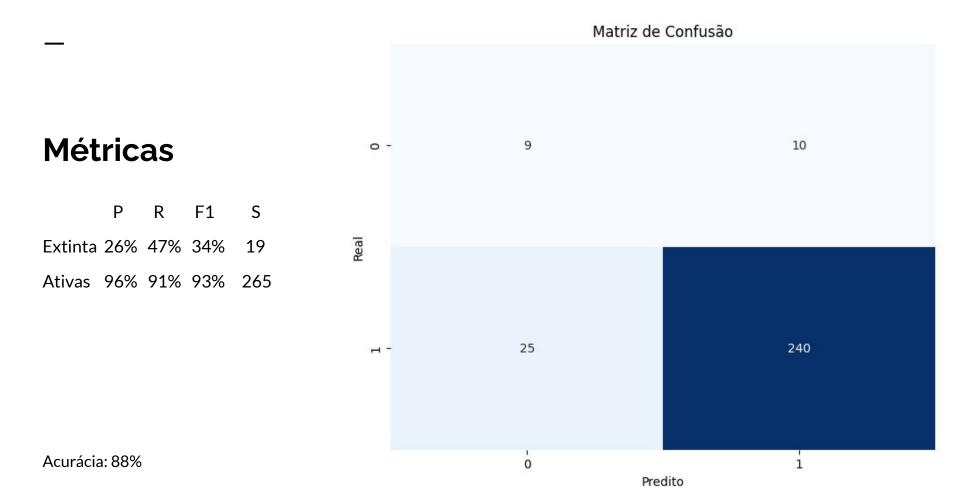
Modelo 2

Árvore de Decisão

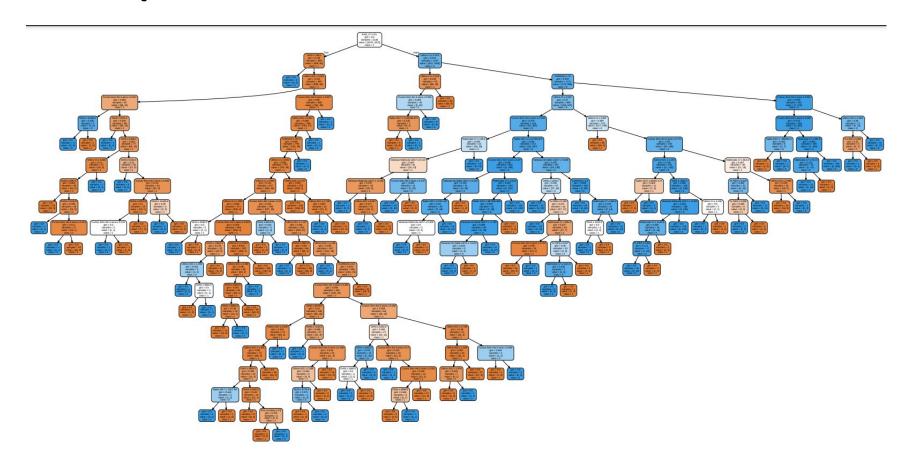
Separeção dos Dados

- 80% treino
- 20% teste

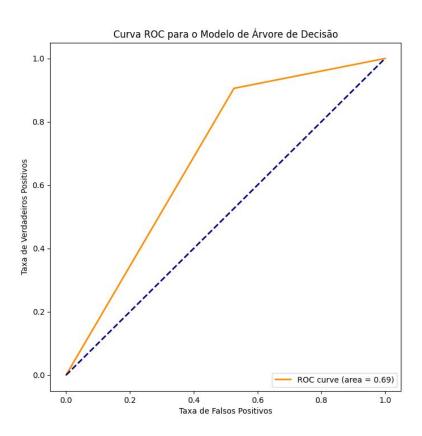
- Sem configuração de hiperparâmetros



Visualização da árvore



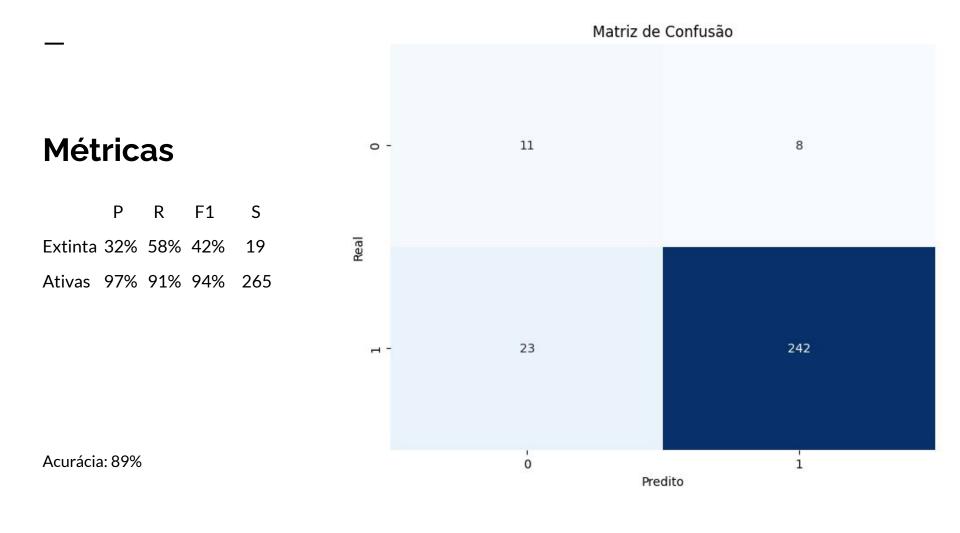
Curva ROC



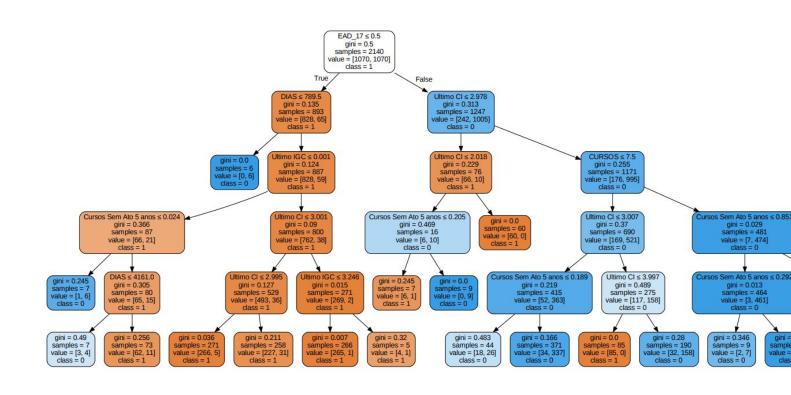
Separeção dos Dados

- 80% treino
- 20% teste

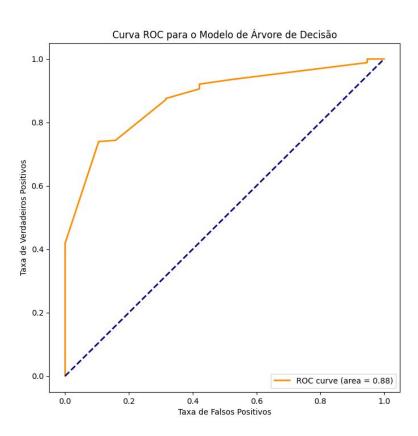
- $max_depth = 5$
- min_samples_split = 5
- min_samples_leaf = 5



Visualização da árvore



Curva ROC



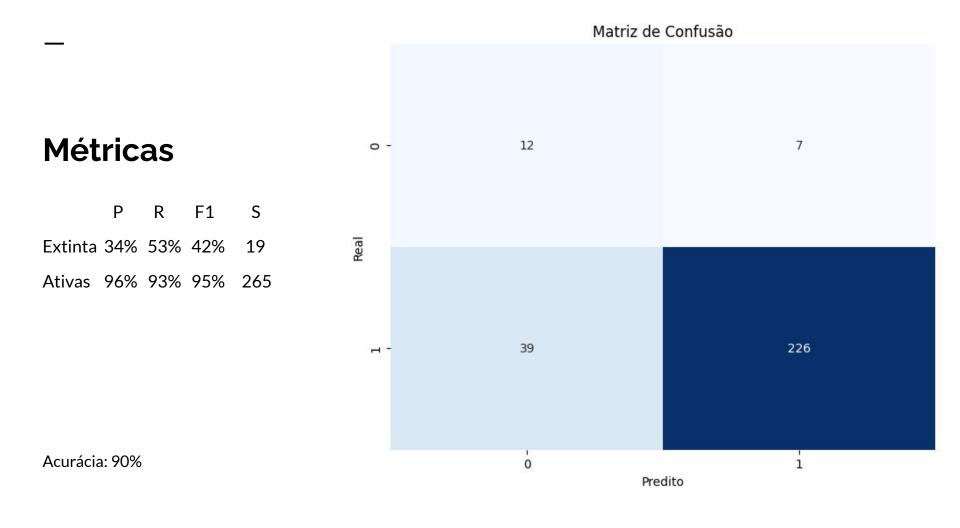
Modelo 3

RandomForest

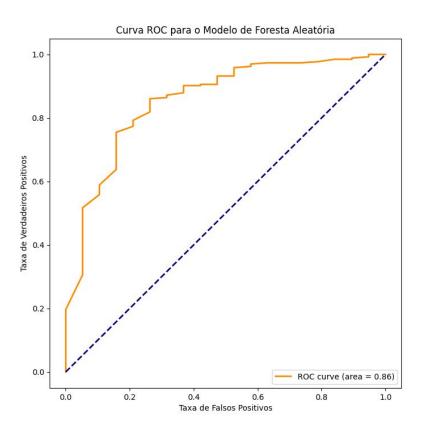
Separeção dos Dados

- 80% treino
- 20% teste

- n_neighbors = 3

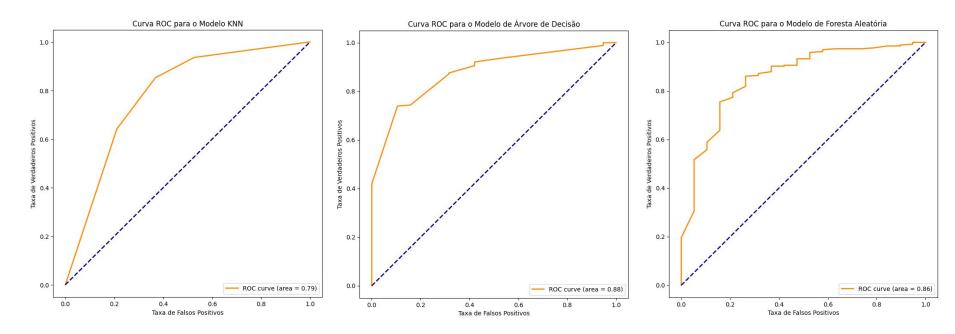


Curva ROC



Conclusões

Comparação da Curva



Comparação

	KNN	Árvore de Decisão	Floresta Aleatória
P(E)	24%	32%	34%
R(E)	63%	58%	53%
F1(E)	34%	42%	42%
P(A)	97%	97%	96%
R(A)	85%	91%	93%
F1(A)	91%	94%	95%
Acurácia	84%	89%	90%

Melhor Modelo

 Árvore de Decisão se mostrou mais interessante em relação a curva ROC

Principais Indicadores

- EAD_17
- Curso Sem Ato 5 anos
- DIAS
- Ultimo IGC
- Ultimo CI

Obrigado!